

用于图分类的矩阵残差图神经网络

中文确认稿

胡雪林 付晓琴

2026 年 6 月 1 日

摘要

背景：残差连接被广泛用于稳定图神经网络训练，但现有残差设计通常被简化为沿深度方向的一维选择。对于多分支图分类器，残差信息不仅可以沿层深方向流动，也可以在分支之间横向交换，或者在分支-层二维局部邻域中复用。

方法：本文提出矩阵残差图神经网络 (Matrix-Residual Graph Neural Networks)，将其作为图分类中残差拓扑的受控研究框架。模型族比较五种信息流设计：普通消息传递、纵向残差复用、横向分支交换、局部矩阵残差复用，以及稀疏/门控矩阵残差复用。主实验覆盖六个数据集、四种消息传递算子、五类模型和五折图级评估。进一步地，本文进行分支数消融、fold-0 灵敏度扫描、选定 MatrixResGated 候选配置的五折复验和机制分析。为了进一步验证本文方法在不同结构粒度下的有效性，我们补充构建了覆盖五类受控图分布、二至八分类任务的合成多分类 benchmark。

结果：真实数据实验表明，没有单一残差拓扑在不同数据集和算子上普遍最优；分支数消融也呈现数据集依赖的有效工作区间，而不是单调容量收益。合成多分类实验进一步显示，简单基线在低类别任务上仍然有竞争力，但随着结构类别粒度增加，MatrixRes 和 MatrixResGated 表现出更稳定的优势。

结论：残差拓扑、分支数和残差过滤应联合选择。额外分支只有在产生有用功能多样性时才有帮助；否则，残差流量和分支冗余会抵消额外容量。矩阵式复用更适合被理解为一个可调残差族，而不是对简单纵向或横向残差路径的通用替代；其最清晰的优势出现在更细粒度的结构判别任务中。

1 引言

图神经网络 (GNN) 通过反复聚合局部邻域信息来学习图表示 (Gori et al., 2005; Kipf and Welling, 2017)。这种消息传递视角已经成为图分类中的标准工具，因为它能够在可微模型中同时结合节点属性、局部连接和图级结构 (Gilmer et al., 2017; Wu et al., 2021)。在分子图和蛋白质相关 benchmark 中，图标签可能同时依赖局部 motif 和全局结构组织，因此有用的中间证据必须在图级池化之前被保留下来 (Duvenaud et al., 2015; Ying et al., 2018)。

增加深度或引入并行分支可以扩大模型容量，但同时也会改变信息在网络中的传输方式。深层 GNN 可能出现过平滑，即传播过程中节点表示变得过于相似 (Li et al., 2018; Oono and Suzuki, 2020)。它们也可能出现过压缩，即远距离信息被压缩进有限维度的消息中 (Alon and Yahav, 2021; Topping et al., 2021)。这些问题对图级预测尤其重要，因为最终 readout 依赖于到达池化阶段的中间表示质量。

残差连接是应对这些困难的常见方法。它们能够改善梯度流并允许早期表示被复用，这一原则首先在深层卷积网络中确立，随后被引入图结构模型 (He et al., 2016; Bresson and Laurent, 2017)。其他深度控制策略，包括 DropEdge、Jumping Knowledge 聚合和图特定归一化，也试图在传播过程中保留有用信息 (Rong et al., 2019; Xu et al., 2018)。然而，残差连接在很多图分类模型中仍被视为默认的逐层组件，而不是研究对象本身。多数残差图分类器只沿同一条分支的深度方向复用信息。

一旦模型包含多个分支，沿深度方向的残差复用就只是众多可能路径之一。残差信息还可以在同一深度的相邻分支之间移动，或者通过分支-深度的对角邻域传递。已有图分类研究探索了更强的消息传递算子、层次化池化、注意力以及高阶邻域混合 (Abu-El-Hajja et al., 2019; Bianchi et al., 2020)。这些设计提升了 GNN

的表达能力或聚合能力，但没有隔离残差路由问题：如果某一深度上存在多个分支状态，模型应该只复用同分支上一层状态，还是横向交换分支状态，或者同时结合两个方向形成局部二维残差邻域？

本文将残差复用视为分支-层网格上的结构化设计问题。核心问题不是是否需要 skip connection，而是残差信号应该流向哪里。网格视角暴露出三个可控邻域：沿深度方向的纵向复用、相邻分支之间的横向交换，以及同时结合同分支、邻分支和对角路径的矩阵式复用。稀疏/门控矩阵变体进一步检验矩阵残差流量在注入前是否需要过滤。该框架遵循受控 benchmark 的思想：目标不是加入大量无关架构组件，而是把一个设计轴显式化到可以评估的程度 (Keriven et al., 2020; Morris et al., 2020)。

本研究刻意采用受控设置。每个比较都固定图分类流程，在若干经典消息传递算子下评估同一架构族，并且只改变残差拓扑和残差控制机制。这种分离使经验比较聚焦于信息流设计，而不是 readout 结构、任务特定特征工程或算子特定调参的混合影响。近年的图模型可能通过同时改变多个组件取得更强绝对性能；本文有意固定这些组件，以便识别残差拓扑本身的作用。

真实图 benchmark 在结构类别粒度上也存在限制。某一种残差拓扑可能在二分类图任务上已经足够，但当标签空间要求更细粒度的结构区分时，其表现可能发生变化。为在不加入任务特定特征工程的情况下检验这一点，本文补充受控合成图族，其类别标签由结构参数生成。该合成设置并不是为了替代真实 benchmark，而是作为压力测试，用来观察结构类别变得更细时残差路由是否仍然稳定。

本文围绕三个研究问题展开：

1. 残差拓扑在统一图分类协议下是否影响性能？在保持其他流程固定的前提下，比较普通消息传递、纵向残差复用、横向分支交换、局部矩阵残差复用和稀疏/门控矩阵残差复用。
2. 分支数、残差流量和机制指标如何解释性能变化？检验额外分支是否单调提升准确率，还是只在某一有效工作区间内有益，并将这些趋势与多样性、相似度、梯度和残差流量联系起来。
3. 在真实数据和受控合成多分类结构中，矩阵式残差复用何时更有效？检验矩阵残差流量应当密集传递还是被过滤，候选残差控制设置在完整五折复验后是否仍然成立，以及结构类别粒度增加时矩阵式复用是否更加稳定。

主要贡献如下：

- 提出图分类残差模型的分支-层表述。纵向、横向、矩阵和稀疏/门控矩阵残差族被统一表达为同一网格上的局部邻域，使其信息流差异更加明确。
- 开展真实 benchmark 与合成多分类 benchmark 的受控实验。实验保持分类器、readout、折划分协议和 backbone 选择一致，并补充覆盖五类受控图分布、二至八分类任务的结构压力测试。
- 结合机制分析与保守复验策略解释残差行为。本文联合分析分支多样性、分支余弦相似度、分支 CKA、梯度范数和残差活跃度；灵敏度扫描仅用于发现候选设置，选出的候选必须跨折复验后才被视为经验证据。

2 材料与方法

本节定义图分类任务、矩阵残差架构族、benchmark 协议、合成结构压力测试和机制指标。基本原则是在固定其余学习流程的同时隔离残差拓扑。

2.1 问题定义与符号

设 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 为一个图，节点特征矩阵为 $\mathbf{X} \in \mathbb{R}^{n \times d_{\text{in}}}$ ，邻接结构为 $\mathbf{A}$ 。对于数据集 $\mathcal{D} = \{(\mathcal{G}_i, y_i)\}_{i=1}^N$ ，目标是学习 $f_{\theta}: \mathcal{G} \rightarrow \hat{y}$ ，其中 $\hat{y}$ 是预测图标签。

比较的模型族共享同一个图分类 wrapper：

- **Plain:** 堆叠消息传递，不使用显式残差复用。

- **VerticalRes**: 从上一层复用同一分支的残差。
- **HorizontalRes**: 在同一深度的相邻分支之间进行跨分支交换。
- **MatrixRes**: 在纵向、横向和对角邻居上进行局部二维复用。
- **MatrixResGated**: 带门控或稀疏残差过滤的矩阵复用。

2.2 共享图分类流程

令 B 为分支数, L 为消息传递层数。第 b 个分支在第 ℓ 层的隐藏状态记为 $\mathbf{H}_b^{(\ell)}$, 其中 $b \in \{1, \dots, B\}$ 。分支局部传播步骤为

$$\mathbf{Z}_b^{(\ell)} = \phi_b^{(\ell)} \left(\mathbf{H}_b^{(\ell-1)}, \mathbf{A} \right), \quad (1)$$

其中 ϕ 被实例化为四种标准算子之一: GCNConv (Kipf and Welling, 2017)、GATConv (Veličković et al., 2018)、SAGEConv (Hamilton et al., 2017) 或 GINConv (Xu et al., 2019)。带残差增强的更新为

$$\mathbf{H}_b^{(\ell)} = \mathbf{Z}_b^{(\ell)} + \sum_{(b', \ell') \in \mathcal{N}(b, \ell)} \mathcal{R}_{(b', \ell') \rightarrow (b, \ell)} \left(\mathbf{H}_{b'}^{(\ell')} \right). \quad (2)$$

不同架构之间唯一变化的项是残差邻域 $\mathcal{N}(b, \ell)$ 和残差变换 $\mathcal{R}$ 。

在最后一层消息传递后, 每个分支通过 global mean pooling 得到图级向量, 然后合并分支向量用于分类。本文有意避免使用差异化池化或自注意力池化等架构特定 readout (Ying et al., 2018; Lee et al., 2019), 因为目标是隔离残差拓扑, 而不是比较 readout 机制。分类器使用交叉熵损失训练。

2.3 残差邻域

Plain. Plain 基线没有残差邻域:

$$\mathcal{N}(b, \ell) = \emptyset. \quad (3)$$

VerticalRes. 纵向残差复用注入同一分支上一层状态:

$$\mathcal{N}(b, \ell) = \{(b, \ell - 1)\}. \quad (4)$$

HorizontalRes. 横向残差复用在同一深度的相邻分支之间交换信息:

$$\mathcal{N}(b, \ell) = \{(b - 1, \ell), (b + 1, \ell)\}, \quad (5)$$

边界分支只使用合法邻居。

MatrixRes. 矩阵残差复用结合纵向、横向和对角邻域:

$$\mathcal{N}(b, \ell) = \{(b, \ell - 1), (b - 1, \ell), (b + 1, \ell), (b - 1, \ell - 1), (b + 1, \ell - 1)\}. \quad (6)$$

该局部 stencil 有意不采用密集 all-to-all 混合, 从而在分支-层网格上保留可解释的残差结构。

MatrixResGated. MatrixResGated 使用与 MatrixRes 相同的邻域, 但残差变换控制注入信号:

$$\mathcal{R}(\mathbf{U}) = \begin{cases} \alpha \mathbf{U}, & \text{带门控的恒等残差过滤,} \\ \alpha \text{softshrink}_{\lambda}(\mathbf{U}), & \text{带门控的稀疏残差过滤.} \end{cases} \quad (7)$$

主 benchmark 中, Plain、VerticalRes、HorizontalRes 和 MatrixRes 使用恒等残差过滤。MatrixResGated 使用 $\lambda = 0.05$ 的稀疏残差过滤, 并使用初始值为 0.8 的可学习标量门控。实现中也支持 top- k 残差过滤和固定门控, 但这些不是主结果的默认设置。

2.4 数据集与评估协议

主 benchmark 使用六个 TUDataset 数据集 (Morris et al., 2020): PROTEINS、DD、ENZYMES、MUTAG、AIDS 和 Mutagenicity。PROTEINS 和 DD 是二分类蛋白质结构图分类 benchmark, ENZYMES 是六分类酶分类 benchmark, MUTAG、AIDS 和 Mutagenicity 作为补充分子图稳健性检查。所有数据集通过 PyTorch Geometric 加载 (Fey and Lenssen, 2019)。所有实验使用原始 benchmark 特征和图结构, 不加入任务特定特征工程、图增强或边重设计。

所有主结果采用图级五折评估。对于第 k 折, 测试准确率为

$$\text{Acc}_k = \frac{1}{|\mathcal{T}_k|} \sum_{(\mathcal{G}_i, y_i) \in \mathcal{T}_k} \mathbf{1}[\hat{y}_i = y_i]. \quad (8)$$

跨折结果报告为

$$\overline{\text{Acc}} = \frac{1}{5} \sum_{k=1}^5 \text{Acc}_k, \quad (9)$$

并同时报告折级标准差。

2.5 合成多分类结构 benchmark

为在受控结构类别粒度下测试残差拓扑, 本文加入五类合成图族: 实验记录中标为 ER 的 Bernoulli 随机图、Barabási–Albert (BA) 图、随机块模型 (SBM)、Watts–Strogatz (WS) 图和正则度对照图。对于每个图族, 生成七个多分类数据集, 类别数为 $C \in \{2, 3, 4, 5, 6, 7, 8\}$ 。每个类别包含 200 个图, 因此每个数据集包含 $200C$ 个图。图规模在 30 至 80 个节点之间采样, 每个节点具有八维特征, 特征由归一化度和随机特征通道组成。节点特征有意保持通用, 不直接编码类别标签。

合成标签由图族特定结构参数控制。实验记录中的 ER 标签严格对应 Gilbert 的 $G(n, p)$ 模型: 每对节点独立地以 Bernoulli 概率 p 连接, 用于构造不同密度的稀疏随机结构 (Gilbert, 1959)。BA 类别通过 preferential-attachment 连接数区分, 用于构造具有长尾度结构的图 (Barabási and Albert, 1999)。SBM 类别通过块内与块间连接概率控制社区分离度 (Holland et al., 1983)。WS 类别通过重连概率区分, 用于构造局部聚类与较短路径并存的小世界结构 (Watts and Strogatz, 1998)。正则度对照图通过随机重标号的正则环形格点构造, 并以固定度区分类别; 该实现用于提供度均匀结构, 而不是从均匀随机正则图分布中采样, 后者可参见 (Wormald, 1999)。这些图族被用作残差拓扑压力测试, 而不是替代真实图分类 benchmark。

合成 benchmark 使用与主 benchmark 相同的五类模型、四种消息传递算子、分支数 $B = 3$ 和五折协议, 共包含 35 个数据集和 3,500 个已完成模型运行。由于不同类别数下的准确率不能直接比较, 本文除原始准确率外还报告 macro-F1 和机会归一化准确率。对于 C 分类数据集, 归一化准确率定义为

$$\text{NAcc} = \frac{\text{Acc} - 1/C}{1 - 1/C}. \quad (10)$$

该指标将随机机会水平映射为 0, 将完美准确率映射为 1, 从而更便于解释二分类到八分类的变化趋势。

2.6 训练配置

所有主 benchmark 运行使用默认分支数 $B = 3$ 。benchmark 在四种消息传递算子下重复: GCNConv、GATConv、SAGEConv 和 GINConv。除灵敏度设置改变外, 隐藏维度为 64; 所有模型族使用相同优化器、早停逻辑、图池化和折划分协议。模型使用 Adam 优化 (Kingma and Ba, 2014); 保留验证损失最低的 checkpoint 用于测试评估。分支数消融在 PROTEINS 和 DD 上、GCNConv 下, 对 HorizontalRes、MatrixRes 和 MatrixResGated 评估 $B = 1, \dots, 8$ 。灵敏度扫描在 fold 0、 $B = 3$ 下评估 MatrixRes 和 MatrixResGated, 变化学习率、dropout、隐藏维度、稀疏强度和门控初始化。选定的 MatrixResGated 候选随后在五折上复验。

表 1: 主 benchmark 共享的关键实验设置。

参数	取值
消息传递算子	GCNConv, GATConv, SAGEConv, GINConv
默认分支数	3
默认隐藏维度	64
评估方式	五折图分类
合成压力测试	ER、BA、SBM、WS 和正则度对照图, $C = 2, \dots, 8$, 每类 200 个图
分支数消融	$B = 1, \dots, 8$
主要指标	平均最佳测试准确率; 合成 benchmark 另报告 macro-F1 和归一化准确率
灵敏度范围	Fold 0, $B = 3$
早停策略	验证损失, patience 为 60 或 80

2.7 机制指标

为解释分支数行为, 本文跟踪五类机制指标。分支多样性度量分支表示之间的平均成对距离。分支余弦相似度和分支 CKA 衡量分支是否冗余或高度对齐。平均梯度范数跟踪分支数和残差流量增长时优化信号是否削弱。残差计数和活跃比例汇总实际注入的残差流量, 尤其用于解释稀疏/门控变体。

3 结果

除非另有说明, 所有结果均报告五折平均最佳测试准确率 $\pm$ 折级标准差。

3.1 整体 benchmark 性能

主 benchmark 检验残差拓扑在不同数据集和消息传递算子上是否存在稳定赢家。结果显示并不存在。表 2 总结完整 benchmark: 在 24 个数据集-算子组合中, MatrixRes 是整体最强拓扑, 胜出 9 次并取得最佳平均排名 (2.12)。MatrixResGated 和 Plain 各胜出 5 次, HorizontalRes 胜出 3 次, VerticalRes 胜出 2 次。因此, 矩阵式复用是本 benchmark 中最强的一般设计, 但每种拓扑都有自己最强的场景。

表 2: 24 个数据集-算子组合上的胜出次数和平均排名。平均排名越低越好。

模型	胜出次数	平均排名	解释
Plain	5	3.04	在部分小规模或较容易设置上表现强
VerticalRes	2	3.38	深度方向复用选择性有益
HorizontalRes	3	3.54	横向交换足够时具有竞争力
MatrixRes	9	2.12	整体最强残差拓扑
MatrixResGated	5	2.92	稀疏控制有助于残差流量时有效




图 1: 六个数据集和四种消息传递算子上的模型级胜出次数。

表 3 给出了表 2 胜出统计背后的逐单元证据。矩阵族在 MUTAG、AIDS 和 Mutagenicity 上最突出，其中多数算子设置由 MatrixRes 或 MatrixResGated 胜出。蛋白质相关数据集更加混合：PROTEINS 在 Plain 和 HorizontalRes 之间交替，DD 在 HorizontalRes、MatrixRes 和 VerticalRes 之间交替。ENZYMES 仍然较困难，没有形成稳定的残差拓扑偏好。

表 3: 每个数据集和消息传递算子下的优胜模型。括号中为平均最佳测试准确率。

数据集	GCNConv	GATConv	SAGEConv	GINConv
PROTEINS	Plain (0.7044)	HorizontalRes (0.7116)	Plain (0.6999)	HorizontalRes (0.7080)
DD	HorizontalRes (0.7181)	MatrixRes (0.7164)	MatrixRes (0.7198)	VerticalRes (0.7224)
ENZYMES	MatrixResGated (0.2933)	Plain (0.2717)	VerticalRes (0.2883)	Plain (0.3100)
MUTAG	MatrixRes (0.7609)	MatrixResGated (0.7555)	MatrixRes (0.7504)	MatrixResGated (0.8081)
AIDS	MatrixRes (0.8365)	MatrixRes (0.8875)	Plain (0.8850)	MatrixResGated (0.9280)
Mutagenicity	MatrixRes (0.7784)	MatrixRes (0.7909)	MatrixResGated (0.8031)	MatrixRes (0.8024)

3.2 GCNConv benchmark 切片

为进一步排除消息传递算子差异的干扰，并观察在固定 backbone 下残差拓扑本身的作用，本文单独报告 GCNConv 切片结果。表 4 给出默认分支数 $B = 3$ 下的完整切片。Plain 在 PROTEINS 上最强，HorizontalRes 在 DD 上最强，MatrixResGated 在 ENZYMES 上最强，MatrixRes 在 MUTAG、AIDS 和 Mutagenicity 上最强。

表 4: 默认分支数 $B = 3$ 下的 GCNConv benchmark 结果。

数据集	Plain	VerticalRes	HorizontalRes	MatrixRes	MatrixResGated
PROTEINS	0.7044 $\pm$ 0.0387	0.6993 $\pm$ 0.0340	0.6992 $\pm$ 0.0399	0.6973 $\pm$ 0.0324	0.6886 $\pm$ 0.0397
DD	0.7053 $\pm$ 0.0517	0.7143 $\pm$ 0.0260	0.7181 $\pm$ 0.0296	0.7127 $\pm$ 0.0365	0.7141 $\pm$ 0.0359
ENZYMES	0.2683 $\pm$ 0.0343	0.2550 $\pm$ 0.0455	0.2633 $\pm$ 0.0584	0.2750 $\pm$ 0.0577	0.2933 $\pm$ 0.0470
MUTAG	0.7556 $\pm$ 0.0439	0.7451 $\pm$ 0.0695	0.7343 $\pm$ 0.0433	0.7609 $\pm$ 0.0715	0.7556 $\pm$ 0.0721
AIDS	0.8215 $\pm$ 0.0046	0.8210 $\pm$ 0.0233	0.8130 $\pm$ 0.0297	0.8365 $\pm$ 0.0412	0.8150 $\pm$ 0.0231
Mutagenicity	0.7644 $\pm$ 0.0188	0.7667 $\pm$ 0.0212	0.7738 $\pm$ 0.0134	0.7784 $\pm$ 0.0185	0.7701 $\pm$ 0.0165




图 2: $B = 3$ 下的 GCNConv benchmark。柱状图表示五折平均最佳测试准确率，误差线表示折级标准差。

GCNConv 切片支持与完整 benchmark 相同的结论: 残差拓扑很重要, 但最佳拓扑依赖数据集。MatrixRes 是六个 GCNConv 数据集中三个数据集的最强默认选择, 但在 PROTEINS 和 DD 上, 更简单的残差路径仍然更优。

3.3 合成多分类扩展实验

合成 benchmark 回答的问题与真实数据 benchmark 不同: 当结构类别粒度在受控图生成规则下增加时, 残差拓扑是否表现出不同趋势? 表 5 汇总了五类合成图族和四种消息传递算子上的类别数变化趋势。二分类和三分类设置并不偏向矩阵式复用: $C = 2$ 时 Plain 最强, $C = 3$ 时 HorizontalRes 最强。从 $C = 4$ 开始, 矩阵式复用变得更有竞争力。MatrixResGated 在 $C = 4$ 、 $C = 5$ 、 $C = 6$ 和 $C = 8$ 时取得最高平均准确率, 而 VerticalRes 在 $C = 7$ 时最强。

表 5: 五类图族和四种算子上合成多分类扩展结果的平均值。NAcc 表示机会归一化准确率。

类别数	最优模型	最优 Acc.	Plain Acc.	MatrixRes Acc.	MatrixResGated Acc.	最优 NAcc
2	Plain	0.9585	0.9585	0.9481	0.9578	0.9170
3	HorizontalRes	0.8800	0.8774	0.8600	0.8772	0.8200
4	MatrixResGated	0.8111	0.8002	0.8083	0.8111	0.7481
5	MatrixResGated	0.7296	0.7233	0.7280	0.7296	0.6621
6	MatrixResGated	0.6878	0.6719	0.6827	0.6878	0.6254
7	VerticalRes	0.6524	0.6314	0.6429	0.6395	0.5945
8	MatrixResGated	0.6035	0.5865	0.6002	0.6035	0.5469



图 3: 二分类到八分类的合成多分类扩展趋势。每个点为五类合成图族和四种消息传递算子的平均值。

表 6 聚焦于较高类别区间 $C = 4, \dots, 8$, 此时任务需要更细粒度的结构判别。MatrixResGated 在该区间取得最高平均准确率和归一化准确率, 相比 Plain 将准确率从 0.6827 提升到 0.6943。MatrixRes 在所有模型

中取得最高 macro-F1，并且在归一化准确率上接近 MatrixResGated。图 3 还显示出稳定性差异：从 $C = 2$ 到 $C = 8$ ，MatrixRes 的准确率下降 0.3479，而 Plain 下降 0.3720。因此，合成 benchmark 支持一个更精确的结论：矩阵式复用对于低类别简单任务并非必要，但当结构标签更加细粒度时，它变得更有利。

表 6: $C = 4, \dots, 8$ 高类别区间上的合成 benchmark 平均结果。

模型	Accuracy	Macro-F1	NAcc
Plain	0.6827	0.6703	0.6183
VerticalRes	0.6931	0.6834	0.6307
HorizontalRes	0.6846	0.6722	0.6210
MatrixRes	0.6924	0.6880	0.6300
MatrixResGated	0.6943	0.6876	0.6324

3.4 分支数消融

分支数不是单纯的容量参数，它同时改变残差路径密度，因此需要单独消融。表 7 报告每种拓扑的最佳和最差分支数。在 PROTEINS 上，有效区域是中等分支数：HorizontalRes 在 $B = 4$ 达峰，MatrixRes 在 $B = 6$ 达峰，MatrixResGated 在 $B = 3$ 达峰。在 DD 上，有效区域更小：HorizontalRes 和 MatrixRes 在 $B = 2$ 达峰，而 MatrixResGated 在 $B = 1$ 时已经最强。这说明 PROTEINS 更适合中等分支，DD 更偏好较小分支，分支扩展必须与任务结构匹配。

表 7: 消融实验中的最佳和最差分支数设置。

数据集	模型	最佳 B	最佳准确率	最差 B	最差准确率
PROTEINS	HorizontalRes	4	0.7125 $\pm$ 0.0286	1	0.6801 $\pm$ 0.0518
PROTEINS	MatrixRes	6	0.7062 $\pm$ 0.0210	1	0.6909 $\pm$ 0.0586
PROTEINS	MatrixResGated	3	0.7098 $\pm$ 0.0219	4	0.6711 $\pm$ 0.0471
DD	HorizontalRes	2	0.7275 $\pm$ 0.0304	4	0.7071 $\pm$ 0.0302
DD	MatrixRes	2	0.7206 $\pm$ 0.0411	7	0.7071 $\pm$ 0.0390
DD	MatrixResGated	1	0.7283 $\pm$ 0.0244	7	0.7053 $\pm$ 0.0456




图 4: HorizontalRes、MatrixRes 和 MatrixResGated 在 PROTEINS 与 DD 上的分支数消融。曲线并非单调上升：准确率只在有效工作区间内提升，随后饱和或下降。

表 7 和图 4 表明，分支数不应被简单理解为容量旋钮。增加 B 会改变残差图本身：它会增加分支、残差路径、残差流量和优化交互。PROTEINS 能容忍适度分支扩展，而 DD 对冗余分支扩展更加敏感。

3.5 机制分析：多样性、相似度、梯度与残差流量

为了说明分支数变化背后的原因，而不仅仅报告准确率，本文进一步分析分支多样性、分支余弦相似度、分支 CKA 相似度、代表性梯度范数、残差计数总量、活跃比例和门控值。表 8 报告每个消融目标在最佳分支数处的机制指标。多样性衡量分支表示之间的距离；分支余弦和分支 CKA 衡量表示冗余或对齐；梯度范数刻画优化信号；残差计数和活跃比例描述注入模型的残差流量。

表 8: 各消融目标最佳分支数处的机制指标。

数据集	模型	B	Acc.	Diversity	Cosine	CKA	Grad.	Residuals	Active	Gate
PROTEINS	HorizontalRes	4	0.7125	1.1450	0.8417	0.9797	0.0157	24.0	0.2519	0.7911
PROTEINS	MatrixRes	6	0.7062	3.7755	0.9173	0.9634	0.0182	88.0	0.4273	0.7757
PROTEINS	MatrixResGated	3	0.7098	1.3555	0.9790	0.9988	0.0316	37.0	0.3121	0.7833
DD	HorizontalRes	2	0.7275	0.1687	0.9969	1.0000	0.0732	6.0	0.3492	0.8375
DD	MatrixRes	2	0.7206	0.1834	0.9991	1.0000	0.0796	14.0	0.5384	0.8222
DD	MatrixResGated	1	0.7283	0.0000	1.0000	1.0000	0.0821	2.0	0.2352	0.8221

PROTEINS 消融显示，适度分支分离是有用的。HorizontalRes 从 $B = 1$ 到 $B = 4$ 提升时，分支多样性从 0.0000 增加到 1.1450，分支余弦从 1.0000 降至 0.8417。然而，多样性本身并不保证准确率提升：在 $B = 8$ 时，多样性进一步升至 1.5441，但准确率降至 0.6881。MatrixRes 在更大尺度上呈现类似规律。它在 $B = 6$ 达峰，此时分支多样性达到 3.7755，但继续增加分支并不能进一步提升准确率。

DD 更保守。HorizontalRes 在 $B = 2$ 达到最佳，此时分支多样性仅为 0.1687，分支余弦仍为 0.9969。MatrixRes 也在 $B = 2$ 达峰，并具有类似的高分支余弦 (0.9991)。在 DD 上，较大分支数会提高多样性，但性能不提升。这说明 DD 不会奖励更大的残差邻域，除非新增分支产生足够有用的功能分离。

稀疏/门控模型进一步说明了残差控制的作用。MatrixResGated 在 PROTEINS 最佳设置上的活跃比例为 0.3121，在 DD 最佳设置上为 0.2352。这说明稀疏过滤确实抑制了部分残差项，而不是退化为密集残差路径。同时，MatrixResGated 并不整体支配 MatrixRes，因此稀疏控制应被视为有用的流量控制机制，而不是普遍改进。




图 5: 机制摘要：连接分支数准确率、分支多样性、分支余弦相似度、分支 CKA 和平均梯度范数。

3.6 MatrixRes 与 MatrixResGated 灵敏度

fold-0 灵敏度扫描用于识别 MatrixRes 和 MatrixResGated 的候选工作区域。这些扫描用于诊断，而不是最终性能声明。在 PROTEINS 上，MatrixRes 在测试 sweep 中没有超过其 fold-0 基线，而 MatrixResGated 受益于轻度稀疏化： $\lambda = 0.02$ 将 fold-0 准确率从 0.6726 提升到 0.6951。更强稀疏化是有害的。在 DD 上，MatrixRes 和 MatrixResGated 在 fold-0 扫描中都偏好较小隐藏维度：MatrixRes 在 $d = 32$ 时达到 0.7595，

MatrixResGated 在 $d = 32$ 时达到 0.7511。MatrixResGated 在 $lr = 0.001$ 和 $gate_init = 0.2$ 时也达到 0.7511。

表 9: MatrixRes 和 MatrixResGated 的最佳 fold-0 灵敏度设置。

数据集	模型	基线	最佳设置	最佳准确率
DD	MatrixRes	0.7468	$dim = 32$	0.7595
DD	MatrixResGated	0.7300	$dim = 32$	0.7511
PROTEINS	MatrixRes	0.6637	baseline	0.6637
PROTEINS	MatrixResGated	0.6726	$\lambda = 0.02$	0.6951

MatrixResGated sensitivity slices




图 6: $B = 3$ 下 fold-0 MatrixResGated 灵敏度扫描。该扫描用于识别候选工作区域，不被视为最终超参数证据。

3.7 调参候选五折复验

fold-0 扫描只用于候选发现，不能直接作为稳定性能证据。为获得更可靠的比较，本文将选定的 MatrixResGated 设置重新运行五折。表 10 报告这些后续复验。DD 上隐藏维度为 32 的 MatrixResGated 候选配置将参数量从 42,371 降至 15,043，同时保持竞争力，说明较小隐藏维度具有更好的参数效率。较低学习率接近默认 MatrixResGated benchmark，较低门控初始化较弱。在 PROTEINS 上，稀疏强度为 $\lambda = 0.02$ 的候选配置没有在五折中稳定保持 fold-0 优势，因此不能据此过度声明稀疏化收益。

调参候选复验避免了从 fold-0 灵敏度结果过度宣称。它支持 DD 上较小且参数更高效的 MatrixResGated 配置，但不支持 PROTEINS 上强五折稀疏收益声明。

表 10: 选定 MatrixResGated 候选的五折复验。

候选	数据集	准确率	平均损失	参数量
隐藏维度 32	DD	0.7215 ± 0.0330	0.5717	15,043
门控初始化 0.2	DD	0.7131 ± 0.0213	0.5820	42,371
学习率 0.001	DD	0.7181 ± 0.0336	0.5737	42,371
稀疏强度 $\lambda = 0.02$	PROTEINS	0.6909 ± 0.0447	0.6104	38,339

4 讨论

本节结合六数据集、四算子 benchmark、分支数消融、调参候选复验、机制证据和合成多分类扩展实验回答研究问题。

4.1 RQ1: 残差拓扑在统一图分类协议下是否影响性能?

主 benchmark 反对存在通用残差拓扑的假设。在 24 个数据集-算子组合中, MatrixRes 是最频繁胜出的模型, 并具有最佳平均排名, 但五个模型族都至少胜出两次。仅在 GCNConv 下, Plain 在 PROTEINS 上最强, HorizontalRes 在 DD 上最强, MatrixResGated 在 ENZYMES 上最强, MatrixRes 在 MUTAG、AIDS 和 Mutagenicity 上最强。这些结果说明, 有用残差邻域取决于数据集对分支专门化、残差流量和优化复杂度的容忍度。

这一结论与更广泛的 GNN 文献一致: 改变传播算子、归一化或池化设计通常会改变偏好的架构 (Xu et al., 2019; Hamilton et al., 2017; Veličković et al., 2018; Ying et al., 2018)。本文进一步说明残差拓扑本身也是这种变化的来源。矩阵式复用可以被理解为分支-层网格上的局部残差 stencil, 其思想类似结构化邻域混合 (Abu-El-Haija et al., 2019), 但作用对象是隐藏状态复用而不是图邻接。它的优势因此来自架构组织, 而不是新的消息传递 primitive。

回答: 在当前完整 benchmark 中, MatrixRes 是整体最强拓扑, 但残差拓扑仍然依赖数据集和算子。图分类 benchmark 应同时比较纵向、横向、矩阵式和稀疏/门控复用, 而不应假设某一个残差方向普遍最优。

4.2 RQ2: 分支数、残差流量和机制指标如何解释性能变化?

分支数消融显示, B 不只是容量参数。增加 B 会增加分支、残差路径和优化交互。在 PROTEINS 上, 适度扩展有用: HorizontalRes 在 $B = 4$ 达峰, MatrixRes 在 $B = 6$ 达峰, MatrixResGated 在 $B = 3$ 达峰。在 DD 上, 更小预算更优, 峰值出现在 $B = 1$ 或 $B = 2$ 。机制摘要解释了这种差异。在 PROTEINS 上, $B = 6$ 的 MatrixRes 产生最大分支多样性, 而 HorizontalRes 保持较低分支余弦和较小残差 footprint。在 DD 上, 所有最佳分支设置都具有接近饱和的分支余弦和 CKA, 因此额外残差流量不太可能产生新的有用功能。分支多样性可能随 B 增加, 但如果分支相似度仍高或梯度削弱, 额外分支不会转化为更好分类。

这种“先升后降”行为也是残差 GNN 设计中的实践警告。残差连接常被用于使更深或更宽模型更易优化 (He et al., 2016; Li et al., 2019, 2021), 但多分支残差模型同时改变容量和路由密度。更大的 B 增加隐藏状态被重新注入的路径数, 因此有效区间由功能多样性和残差干扰之间的平衡决定。分支数结果显示, PROTEINS 和 DD 的这种平衡明显不同, 尽管二者都常被视为蛋白质结构图 benchmark。

回答: 分支数在产生有用功能多样性时有帮助; 当残差复杂度增长快于分支分离或优化质量时会造成伤害。

4.3 RQ3: 在真实数据和受控合成多分类结构中, 矩阵式残差复用何时更有效?

MatrixResGated 检验矩阵残差流量在注入前是否应被过滤。主 benchmark 显示, 稀疏/门控复用并不总是优于密集矩阵复用: MatrixRes 在更多数据集-算子组合中胜出。然而, MatrixResGated 仍然有用, 因为它在多个组合中胜出, 包括困难的 ENZYMES GCNConv 设置, 并提供了减少弱残差系数的受控方式。机制

表支持这一解释：门控变体通常比密集 MatrixRes 保持更少活跃残差路径，而学习门控保持在中等范围，并未塌缩为零。这一区分很重要。MatrixResGated 的价值不是稀疏性总能提升准确率，而是当矩阵式复用会注入过多低价值残差流量时，稀疏残差控制可能有益。

稀疏/门控残差复用位于两类熟悉设计之间。类似 residual gated graph networks，它学习历史信息应以多强程度注入 (Bresson and Laurent, 2017)；类似稀疏化和正则化方法，它降低弱或噪声路径影响 (Rong et al., 2019; Cangea et al., 2018)。当前实现有意保持简单：使用标量门控和 soft-shrink 过滤，而不是大型路由网络。这保持了消融的可解释性，也避免门控变体变成另一个高容量模型。

MatrixResGated 定义的是一个可调家族，而不是即插即用的赢家。fold-0 灵敏度扫描提示 PROTEINS 可能受益于轻度稀疏化，而 DD 受益于保守优化、较小隐藏维度和较低初始门控。五折候选复验进一步修正了这一解释。在 DD 上，较小隐藏维度仍然有益且参数高效。在 PROTEINS 上，轻度稀疏候选未能跨所有折保持 fold-0 优势。

真实数据侧。稀疏/门控矩阵复用是残差流量控制机制。它是密集 MatrixRes 的补充，而非严格替代；候选设置必须跨折验证后才应被视为性能声明。当前证据支持 DD 上较小的受控矩阵模型，并将 PROTEINS 稀疏化保留为有前景但尚不稳定的方向。

合成多分类 benchmark 将类别粒度与真实数据集的特定因素分离开来。在二分类和三分类设置中，较简单的残差选择仍然具有竞争力：Plain 在 $C = 2$ 时最强，HorizontalRes 在 $C = 3$ 时最强。这一点很重要，因为它避免了“矩阵式复用总是必要”的过度结论。随着类别数增加，趋势发生变化。在 $C = 4, \dots, 8$ 区间内，MatrixResGated 取得最高平均准确率和归一化准确率，MatrixRes 取得最高 macro-F1。MatrixRes 还具有从 $C = 2$ 到 $C = 8$ 的最小准确率下降幅度，说明密集局部矩阵复用在标签空间变细时相对稳定。

分布级合成结果进一步细化了这一结论。在高类别 BA、ER 和正则度对照图设置中，MatrixRes 最强，这些任务的类别标签分别与度增长、边概率或度均匀结构变化有关。其优势在 SBM 上较弱，在 WS 上不存在；社区结构和小世界重连带来了不同的归纳压力。因此，合成 benchmark 支持的是条件性结论：当任务需要区分多个相关结构状态时，矩阵式残差复用最有用，但它并不能解决所有图分布。

回答：真实数据与合成类别扩展实验共同表明，MatrixRes 和 MatrixResGated 是条件性有效的矩阵残差族，而不是通用替代方案。稀疏/门控机制适合控制过量残差流量；矩阵式复用在更细粒度结构判别中更有用，尤其体现在四分类到八分类区间。该效果在若干受控的度相关和密度相关图族上最强，但仍然依赖图分布。

4.4 局限性

这些发现的泛化性受到若干限制。第一，尽管主 benchmark 包含四种消息传递算子，它仍使用固定图级池化和分类头；其他 readout 设计可能与残差拓扑发生交互。第二，比較的算子是经典消息传递 backbone，而不是近年的 graph transformer 或 local-global hybrid 架构 (Dwivedi and Bresson, 2020)。这是有意的控制选择，但意味着本文不应被解读为 state-of-the-art 模型比较。第三，灵敏度扫描仅为 fold-0；虽然选定候选已跨五折复验，但该复验仅限于 PROTEINS 和 DD 上的 MatrixResGated。第四，ENZYMES 的绝对准确率较低且波动较高，因此应谨慎解释。最后，机制分析是相关性的。分支多样性、余弦相似度、CKA 和梯度范数支持一个一致解释，但不能证明因果关系。

另一个限制是 benchmark 有意避免任务特定的化学或生物特征工程。这使残差拓扑比较更干净，但也意味着绝对准确率不应被解释为优化后的 state-of-the-art 分子预测结果。合成 benchmark 也有类似限制：其标签由受控结构参数生成，因此适合作为残差拓扑压力测试，但不能替代更广泛的真实多分类图 benchmark。本文贡献是方法论层面的：它识别在匹配条件下不同残差路径何时有帮助。

4.5 未来方向

未来工作应将比较扩展到更大图分类数据集、更丰富 readout 机制、近年 local-global backbone，以及自适应残差邻域选择。自然的下一步是用学习得到的局部残差策略替代人工选择的纵向、横向或矩阵 stencil。调参候选验证也应扩展到当前 MatrixResGated 检查之外，以确定是否可以可靠地选择数据集特定残差控制。

5 结论

本文将图分类中的残差连接研究为一个结构化分支-层设计问题。在六个数据集和四种消息传递算子上，残差拓扑确实重要，但其价值取决于数据集、算子和分支预算。MatrixRes 按胜出次数和平均排名是整体最强拓扑，但 GCNConv 下逐数据集赢家仍然混合：PROTEINS 上 Plain 最强，DD 上 HorizontalRes 最强，ENZYMEs 上 MatrixResGated 最强，MUTAG、AIDS 和 Mutagenicity 上 MatrixRes 最强。分支数消融进一步显示，增加分支只在有限工作区间内有用。

机制分析解释了为什么分支扩展并不自动有益。额外分支可以增加表示多样性，但也会增加残差流量，并可能保留冗余分支相似性或削弱优化。矩阵式复用因此更适合被看作一个受控残差家族，其有效性依赖分支预算和残差过滤策略。

合成多分类 benchmark 通过受控图生成规则改变结构类别粒度，进一步支持这一解释。矩阵式复用对于最简单的二分类和三分类设置并非必要，但在四分类到八分类时更加有竞争力。在该高类别区间中，MatrixResGated 取得最高平均准确率和归一化准确率，而 MatrixRes 具有从二分类到八分类的最小准确率下降幅度。这说明当图级分类需要更细粒度结构判别时，矩阵残差邻域最有价值。

实践含义是，残差拓扑、分支数、算子选择和残差控制应联合评估。在将灵敏度结果作为性能声明之前，候选设置应跨折复验。在当前实验中，该验证支持 DD 上更小且参数更高效的 MatrixResGated 模型，而 PROTEINS 稀疏候选仍不够稳定。

6 致谢

作者感谢开源图学习社区以及本研究所用 benchmark 资源的维护者。作者也感谢审稿人和编辑投入时间并提出反馈。

A 附录

A.1 已上传的佐证资料文件

下列 CSV 文件均已随本次投稿作为佐证资料上传，因此不再在论文中单独展示：

- 01_real_data_benchmark_summary.csv
- 02_real_data_branch_ablation_summary.csv
- 03_real_data_parameter_sensitivity_summary.csv
- 04_real_data_tuned_candidate_summary.csv
- 05_real_data_mechanism_compact_summary.csv
- 06_synthetic_multiclass_benchmark_summary.csv

A.2 补充诊断

额外逐折行、CKA 汇总、残差流量汇总和完整灵敏度表保留在仓库 records 目录中，可用于补充材料转换。

A.3 证据映射

表 11 总结每个主要经验结论在正文中的证据来源。该紧凑表用于保持正文可读性，同时明确结果与结论之间的对应关系。

表 11: 经验结论与论文证据之间的紧凑映射。

研究问题	结论	主要证据
RQ1	MatrixRes 是整体最强拓扑, 但不是通用赢家; 固定算子下结果仍然依赖数据集。	表 2、表 3、图 1、表 4 和图 2。
RQ2	分支数呈现“先升后降”, 有效扩展需要表示分离, 同时避免过量残差流量。	表 7、图 4、表 8 和图 5。
RQ3	fold-0 灵敏度不应被当作最终证据; 矩阵式复用在高类别合成结构判别中更有优势。	表 9、图 6、表 10、表 5、图 3、表 6 和表 12。

A.4 合成分布级结果

表 12 按图族报告高类别合成结果。该表放在附录中, 因为正文主要聚焦类别数扩展趋势。结果显示, MatrixRes 在 BA、ER 和正则度对照图上最强, 而 SBM 和 WS 对矩阵式复用并不总是有利。

表 12: 按图族划分的合成高类别准确率, 结果在 $C = 4, \dots, 8$ 和四种算子上平均。

图族	Plain	VerticalRes	HorizontalRes	MatrixRes	MatrixResGated
BA	0.7874	0.8177	0.7855	0.8271	0.8257
ER	0.8777	0.8756	0.8728	0.8807	0.8796
Regular	0.7505	0.7923	0.7739	0.8077	0.8057
SBM	0.6268	0.6286	0.6218	0.6264	0.6176
WS	0.3709	0.3511	0.3693	0.3202	0.3430

参考文献

- Sami Abu-El-Haija, Bryan Perozzi, Aalok Kapoor, Navid Alipourfard, Kristina Lerman, Greg Steeg, and Aram Galstyan. Mixhop: Higher-order graph convolutional architectures via sparsified neighborhood mixing. In *International Conference on Machine Learning*, pages 33–42, 2019.
- Uri Alon and Eran Yahav. On the bottleneck of graph neural networks. In *International Conference on Learning Representations (ICLR)*, 2021.
- Albert-László Barabási and Réka Albert. Emergence of scaling in random networks. *Science*, 286(5439):509–512, 1999. doi: 10.1126/science.286.5439.509. URL <https://doi.org/10.1126/science.286.5439.509>.
- Filippo Maria Bianchi, Franco Grattarola, and Cesare Alippi. Graph neural networks with convolutional arma filters. In *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2020.
- Xavier Bresson and Thomas Laurent. Residual gated graph convnets. *arXiv preprint arXiv:1711.07553*, 2017.
- Cătălina Cangea, Petar Veličković, Nikola Jovanović, Thomas Kipf, and Pietro Liò. Towards sparse hierarchical graph classifiers. In *Pacific-Asia Conference on Knowledge Discovery and Data Mining*, pages 165–176, 2018.
- David K Duvenaud, Dougal Maclaurin, Jorge Iparraguirre, Rafael Bombarell, Timothy Hirzel, Alan Aspuru-Guzik, and Ryan P Adams. Convolutional networks on graphs for learning molecular fingerprints. In *Advances in neural information processing systems*, pages 2224–2232, 2015.
- Vijay Prakash Dwivedi and Xavier Bresson. A generalization of transformer networks to graphs. *arXiv preprint arXiv:2012.09699*, 2020.

- Matthias Fey and Jan Eric Lenssen. Fast graph representation learning with pytorch geometric. *arXiv preprint arXiv:1903.02428*, 2019.
- Edgar N. Gilbert. Random graphs. *The Annals of Mathematical Statistics*, 30(4):1141–1144, 1959. doi: 10.1214/aoms/1177706098. URL <https://doi.org/10.1214/aoms/1177706098>.
- Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. In *International Conference on Machine Learning*, pages 1263–1272, 2017.
- Marco Gori, Gabriele Monfardini, and Franco Scarselli. A new model for learning in graph domains. *Proceedings of IJCNN*, 2005.
- William L Hamilton, Rex Ying, and Jure Leskovec. Inductive representation learning on large graphs. In *Advances in neural information processing systems*, pages 1024–1034, 2017.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- Paul W. Holland, Kathryn Blackmond Laskey, and Samuel Leinhardt. Stochastic blockmodels: First steps. *Social Networks*, 5(2):109–137, 1983. doi: 10.1016/0378-8733(83)90021-7. URL [https://doi.org/10.1016/0378-8733\(83\)90021-7](https://doi.org/10.1016/0378-8733(83)90021-7).
- Nicolas Keriven, Gabriel Peyré, and Samuel Vaiter. A unified benchmark for the diagnosis and treatment of graph neural networks. *arXiv preprint arXiv:2012.01450*, 2020.
- Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- Thomas N. Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. In *International Conference on Learning Representations*, 2017. URL <https://arxiv.org/abs/1609.02907>.
- Junhyun Lee, Inyeop Lee, and Jaewoo Kang. Self-attention graph pooling. *arXiv preprint arXiv:1904.08082*, 2019.
- Guohao Li, Matthias Müller, Ali Thabet, and Bernard Ghanem. DeepGCNs: Can GCNs go as deep as CNNs? In *IEEE/CVF International Conference on Computer Vision*, 2019. URL <https://arxiv.org/abs/1904.03751>.
- Guohao Li, Elias Müller, Abbas Thabet, and Bernard Ghanem. Training graph neural networks with 1000 layers. In *International Conference on Machine Learning*, pages 6403–6413, 2021.
- Qimai Li, Zhichao Han, and Xiao-Ming Wu. Deeper insights into graph convolutional networks for semi-supervised learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2018. URL <https://ojs.aaai.org/index.php/AAAI/article/view/11604>.
- Christopher Morris, Nils M. Kriege, Franka Bause, Kristian Kersting, Petra Mutzel, and Marion Neumann. TUDataset: A collection of benchmark datasets for learning with graphs. In *ICML Workshop on Graph Representation Learning and Beyond*, 2020. URL <https://chrsmrrs.github.io/datasets/>.
- Kenta Oono and Taiji Suzuki. Simple and deep graph convolutional networks. *arXiv preprint arXiv:2006.13604*, 2020.
- Yu Rong, Wenbing Huang, Tingyang Xu, and Junzhou Huang. Dropedge: Towards deep graph convolutional networks on node classification. *arXiv preprint arXiv:1907.10903*, 2019.

- Jake Topping, Francesco Di Giovanni, Benjamin Chamberlain, Michael Bronstein, Douwe Vendrig, and Pietro Lio. Understanding over-squashing and bottlenecks on graphs via curvature. *arXiv preprint arXiv:2111.14522*, 2021.
- Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio. Graph attention networks. In *International Conference on Learning Representations (ICLR)*, 2018.
- Duncan J. Watts and Steven H. Strogatz. Collective dynamics of ‘small-world’ networks. *Nature*, 393:440–442, 1998. doi: 10.1038/30918. URL <https://doi.org/10.1038/30918>.
- Nicholas C. Wormald. Models of random regular graphs. In J. D. Lamb and D. A. Preece, editors, *Surveys in Combinatorics, 1999*, volume 267 of *London Mathematical Society Lecture Note Series*, pages 239–298. Cambridge University Press, 1999. doi: 10.1017/CBO9780511721335.010. URL <https://doi.org/10.1017/CBO9780511721335.010>.
- Zonghan Wu, Shirui Pan, Fengwen Chen, Guoding Long, Cheng Zhang, and Sheng Yu Zhang. A comprehensive survey on graph neural networks. *IEEE Transactions on Neural Networks and Learning Systems*, 32(1):4–24, 2021.
- Keyulu Xu, Chengtao Li, Yonglong Tian, Xiao Du, Jure Leskovec, and Stefanie Jegelka. Representation learning on graphs with jumping knowledge networks. In *International Conference on Machine Learning*, pages 5449–5458, 2018.
- Keyulu Xu, Weihua Hu, Jure Leskovec, and Stefanie Jegelka. How powerful are graph neural networks? In *International Conference on Learning Representations*, 2019. URL <https://openreview.net/forum?id=ryGs6iA5Km>.
- Rex Ying, Jiaxuan You, Christopher Morris, Xiang Ren, William L Hamilton, and Jure Leskovec. Hierarchical graph representation learning with differentiable pooling. In *Advances in neural information processing systems*, pages 4800–4810, 2018.